

Relatório Técnico: People Analytics com Análise de Sobrevivência e Redes Bayesianas

Este relatório detalha a aplicação prática de técnicas de ciência de dados para a análise do IBM HR Attrition. O objetivo é responder *quando* e com *qual intensidade* o risco de saída aumenta (Análise de Sobrevivência) e mapear a arquitetura causal desse risco (Redes Bayesianas).


1. Justificativa Metodológica

1. **Análise de Sobrevivência (Time-to-Event):** Escolhida porque problemas de atrito (turnover) dependem criticamente do tempo. Abordagens clássicas de classificação (como regressão logística ou random forests simples) tratam a variável como estática (“o funcionário saiu ou não?”). A análise de sobrevivência trata os **dados censurados à direita** (funcionários que continuam ativos na empresa e cuja data de demissão não ocorreu até o fim do estudo), modelando *quando* as saídas ocorrem.
 2. **Redes Bayesianas:** Diferente de modelos regressivos (como Cox) que assumem independência condicional das covariáveis e são focados em efeitos lineares aditivos, a Rede Bayesiana modela o espaço de probabilidade conjunta de todas as variáveis simultaneamente. Ela permite descobrir a **topologia causal** (através de Grafos Acíclicos Dirigidos - DAGs), identificando variáveis mediadoras, fatores de confusão e d-separação, além de suportar inferência probabilística flexível sob novos cenários de evidência.
-

PARTE 1: ANÁLISE DE SOBREVIVÊNCIA

Pergunta 1: Função de Sobrevivência Global e Quedas Marginais

- **Questão de Negócio:** Qual é a função de sobrevivência global da base de funcionários ao longo do tempo (t) e em qual ano ocorre a queda mais acentuada na probabilidade marginal de retenção?
- **Solução Técnica:** Estimador não paramétrico de Kaplan-Meier usando `YearsAtCompany` e a variável binária de atrito.
- **Resultados:**
 - A maior queda marginal na probabilidade de retenção ocorre no **Ano 1** (de $t=0$ para $t=1$), com uma perda marginal de **4,09%** na probabilidade de sobrevivência (indo de 98,91% para 94,82%).
 - A segunda maior queda ocorre no **Ano 10** (de $t=9$ para $t=10$), com uma perda marginal de **4,02%** (indo de 81,72% para 77,70%).




- **Visualização:**
- **Insights de Negócio:**
 1. **Gargalo de Onboarding (Ano 1):** Há uma vulnerabilidade inicial severa nos primeiros 12 meses de empresa. Isso sugere problemas na integração (onboarding), desalinhamento de expectativas ou contratação de perfis inadequados.
 2. **Ciclo de Carreira Decenal (Ano 10):** O expressivo drop no ano 10 sinaliza fadiga de carreira ou estagnação de longo prazo. Funcionários que atingem essa marca de senioridade podem sentir que esgotaram suas possibilidades de crescimento interno, demandando planos de rotação horizontal ou incentivos de permanência focados.

Pergunta 2: Diferença nas Horas Extras (Log-Rank Test)

- **Questão de Negócio:** Existe uma diferença estatisticamente significativa na taxa de sobrevivência entre funcionários que fazem horas extras (**OverTime**) e os que não fazem?
- **Solução Técnica:** Teste não paramétrico de Log-Rank comparando as curvas de sobrevivência dos dois estratos.
- **Resultados:**
 - **Estatística do Teste:** $\chi^2 = 81,7$ com 1 grau de liberdade.
 - **p-valor:** $< 2 \times 10^{-16}$ (altamente significativo).

Curva de Sobrevivência: Com vs Sem Hora Extra



- **Visualização:**
- **Insights de Negócio:**
 - O risco de evasão para funcionários que realizam horas extras recorrentes é drasticamente superior. A curva de sobrevivência da população com hora extra cai de forma íngreme.
 - **Implicação:** A cultura de horas extras é um catalisador do desligamento. Programas de mitigação de burnout e controle rígido de cargas de trabalho são críticos para estancar essa perda de talentos.

Pergunta 3: Fatores de Influência no Atrito e sua Intensidade (Cox Estratificado)

- **Questão de Negócio:** O que influencia a saída de funcionários da empresa e qual é o impacto quantitativo exato (Hazard Ratio) de cada um desses fatores no risco de evasão, corrigindo vieses de tempo?
- **Solução Técnica:** Ajuste de um **Modelo de Riscos Proporcionais de Cox Estratificado** (`coxph`) com a variável de estratificação `PromotionStatus` (derivada de `YearsSinceLastPromotion` com corte de 2 anos), controlando o efeito temporal de promoções.
- **Resultados e Estatísticas do Modelo:**
 - **Concordância (Poder Preditivo):** **0,837** (Excelente poder de discriminação temporal dos desligamentos).
 - **Validação de Riscos Proporcionais (PH):** O teste global de Schoenfeld (`cox.zph`) resultou em p-valores plenamente satisfatórios para quase a totalidade das variáveis isoladas (ex: Idade $p = 0,13$; Distância $p = 0,19$; Satisfação no Trabalho $p = 0,20$; Horas Extras $p = 0,36$), corrigindo a séria violação do modelo não estratificado.
 - **Tabela de Impacto dos Fatores (Hazard Ratios e Risco Relativo):**

Dimensão	Variável Coletada	Coefficiente (β)	Hazard Ratio ($HR = e^{\beta}$)	p-valor	Signif.	Impacto no Risco de Evasão
Cultura / Rotina	Hora Extra (OverTime = Yes)	1,2690	3,5573	$< 2 \cdot 10^{-16}$	***	Aumento de 255,73% (risco 3,56x maior)
Mobilidade	Viagem de Negócios Frequente	1,1320	3,1003	0,00035	***	Aumento de 210,03% (risco 3,10x maior)
Demográfico	Estado Civil Solteiro	0,9531	2,5939	$1,81 \cdot 10^{-6}$	***	Aumento de 159,39% (risco 2,59x maior)
Currículo	Nº de Empresas Anteriores	0,1689	1,1840	$3,30 \cdot 10^{-11}$	***	Aumento de 18,40% por empresa anterior
Deslocamento	Distância de Casa (milhas)	0,0311	1,0316	$5,41 \cdot 10^{-5}$	***	Aumento de 3,16% por milha de distância
Compensação	Salário Mensal (por USD 1.000)	-0,1943	0,8234	$3,97 \cdot 10^{-12}$	***	Redução de 17,66% a cada USD 1.000 a mais
Percepção	Satisfação no Trabalho (1 a 4)	-0,2554	0,7746	$1,20 \cdot 10^{-5}$	***	Redução de 22,54% por nível de satisfação
Percepção	Equilíbrio Vida-Trabalho (1-4)	-0,2189	0,8034	0,01536	*	Redução de 19,66% por nível de equilíbrio
Percepção	Satisfação com o Ambiente (1-4)	-0,2148	0,8067	0,00023	***	Redução de 19,33% por nível de satisfação
Demográfico	Idade (anos)	-0,0641	0,9380	$7,30 \cdot 10^{-10}$	***	Redução de 6,20% por ano de idade adicional

*Legenda de Significância: *** $p < 0,001$, * $p < 0,05$. O grupo de referência para Estado Civil é *Divorced* e para Viagens é *Non-Travel*. O modelo é estratificado pela variável *PromotionStatus* (corte de 2 anos).*

- **Insights Estratégicos de Negócio:**

1. **Horas Extras e Viagens:** Fazer hora extra recorrente e viajar a negócios de forma frequente multiplicam o risco por **3,56x** e **3,10x**, respectivamente. Intervenções organizacionais focadas em *workload* nestes grupos são urgentes.
2. **Salário como Âncora Eficiente:** Para cada USD 1.000 adicionais inseridos no salário mensal, amortece o risco de saída em **17,66%**, demonstrando a alta elasticidade da retenção financeira.
3. **Clima e Alinhamento Percebidos:** Um acréscimo de 1 ponto na escala de satisfação com o ambiente ou satisfação com o trabalho atua como um forte escudo protetor, derrubando o risco de atrito em **~19%** e **~22%**, respectivamente.
4. **Importância de Estratificar por Promoções:** Ao isolarmos a baseline de risco de quem não é promovido há muito tempo de quem tem promoções frequentes, eliminamos a distorção (viés) do tempo de promoção no modelo, garantindo coeficientes robustos e corretos para todas as outras variáveis de controle.




PARTE 2: REDES BAYESIANAS

Pergunta 4: Topologia de Dependência Condicional (DAG com Priors)

- **Questão de Negócio:** Qual é a topologia de dependência condicional entre as variáveis organizacionais, de percepção e de rendimento na empresa?
- **Solução Técnica:** Algoritmo Hill-Climbing (hc) baseado em score BIC com dados discretizados e **Priors Estruturais (Whitelist)** de literatura especializada para garantir a conexidade das percepções de clima.

Rede Bayesiana de Attrition (com Priors de Literatura)



- **Visualização:**
- **Relações Causais Aprendidas:**
 - *O Desafio do Puro Algoritmo:* Ao rodarmos o Hill-Climbing sob o critério conservador BIC puro, variáveis perceptivas como satisfação no trabalho (**JobSatisfaction**), no ambiente (**EnvironmentSatisfaction**) e equilíbrio de vida (**WorkLifeBalance**) aparecem isoladas devido à penalização rigorosa de parâmetros do score.
 - *A Solução Humana:* Sabendo pela vasta literatura de psicologia organizacional e HR que o clima afeta a saída de talentos, intervi inserindo uma **Whitelist** para forçar essas três arestas causais direcionadas ao alvo **Attrition**.
 - *A Nova Topologia:* Com os priors integrados, a rede causou um rearranjo de fluxo: **Satisfaction/Balance → Attrition → JobRole → JobLevel → MonthlyIncome**.

Pergunta 5: d-separação (Renda Mensal vs Evasão)

- **Questão de Negócio:** O impacto da renda mensal (**MonthlyIncome**) na evasão é direto, ou essas variáveis tornam-se condicionalmente independentes quando isolamos o nível do cargo (**JobLevel**)?
- **Solução Técnica:** Análise formal de d-separação no grafo resultante.
- **Resultado:**
 - **Teste de d-separação:** `dsep(dag, "MonthlyIncome", "Attrition", "JobLevel")` retornou **TRUE**.
- **Explicação Analítica:**
 - Na rede ajustada com priors, a estrutura causal de renda é uma **Cadeia Serial**: **Attrition → JobRole → JobLevel → MonthlyIncome**.

- Pelas regras da teoria de grafos e redes bayesianas, em um caminho serial, se condicionarmos (ou seja, isolarmos/observarmos) um nó intermediário como **JobLevel**, bloqueamos a propagação de informação causal entre as duas pontas.
- **Impacto Prático:** Renda e demissão são condicionalmente independentes dado o nível do cargo. A renda mensal não tem efeito direto na evasão; em vez disso, o cargo determina o nível salarial, e este por sua vez atua como mediador da estabilidade de carreira.

Pergunta 6: Inferência Bayesiana (Atualização de Crenças)

- **Questão de Negócio:** Diante de novas evidências (funcionário é do departamento de Vendas, viaja frequentemente e tem baixa satisfação com o ambiente), qual é a probabilidade posterior exata de que ele deixe a empresa?
- **Solução Técnica:** Ajuste de probabilidades condicionais (`bn.fit`) e consulta probabilística condicional (`cpquery`) por simulação de Monte Carlo com 10^7 repetições.
- **Resultados:**
 - **Média Geral de Evasão na Empresa (Baseline): 16,12%**
 - **Probabilidade Posterior sob Evidência: 43,94%** (Um salto expressivo).
 - **Risco Relativo:** Aumento de **2,73x** em relação à média geral.
- **Perfil de Evidência:**

Evidence = {Department = "Sales", BusinessTravel = "Travel_Frequently", EnvironmentSatisfaction = "1"}

- **Insights e Comparativo Científico:**
 - No modelo conservador anterior (onde a satisfação do ambiente estava isolada no grafo), a probabilidade posterior sob a mesma evidência subia apenas para **20,64%** (capturando apenas o efeito da viagem frequente).
 - Com a inclusão correta do prior estrutural **EnvironmentSatisfaction -> Attrition**, o modelo tornou-se sensível ao estresse do ambiente, revelando que a insatisfação física combinada à exaustão de viagens na área comercial de Vendas eleva o risco individual para assustadores **43,94%** (quase metade de probabilidade de saída rápida). Isso prova o valor prático da inteligência de dados algorítmica com expertise teórica de negócios.

3. Conclusão e Próximos Passos recomendados

1. **Ações para Integração Inicial (Survival):** Fortalecer o onboarding com mentoria focada nos primeiros 12 meses.
2. **Ações de Mobilidade de Carreira (Survival):** Intervir na janela do 9º ao 10º ano do funcionário com avaliações de carreira customizadas.
3. **Plano de Viagens e Burnout (Bayesian Network):** O departamento de Vendas com viagens constantes representa um “polo de risco” identificado na simulação. Propõe-se rodar dinâmicas de rodízio de viagens para diminuir a exaustão.